



**Universidad
Tecnológica
del Perú**

UNIVERSIDAD TECNOLÓGICA DEL PERÚ

S11.s1 — Trabajo Práctico

Curso

Inteligencia de Negocios

Sección

31677

Integrantes

Ramos Yampufe, Martin Alexander

U22214724

Docente

Tapia Ore, Willy Alexander

Perú

2026

Índice

Introducción	2
Descripción de la Empresa y el Dataset	3
Olist Store	4
Dataset: Brazilian E-Commerce Public Dataset by Olist	4
Problema de Negocio	5
Análisis de las 5Vss	6
Volumen	7
Velocidad	7
Variedad	8
Veracidad	8
Valor	9
Arquitectura Big Data Propuesta	10
Conclusiones	11

Introducción

En la última década, el volumen de datos generados a nivel global ha experimentado un crecimiento exponencial. Se estima que el 90% de todos los datos existentes se han generado únicamente en los últimos dos años. Este fenómeno ha dado lugar al concepto de Big Data, definido originalmente por Doug Laney a principios de los años 2000 mediante tres dimensiones fundamentales: volumen, velocidad y variedad (las 3Vs). Posteriormente, la industria evolucionó hacia un modelo de 5Vs al incorporar la veracidad y el valor como dimensiones críticas para transformar los datos en ventajas estratégicas.

El presente trabajo práctico tiene como objetivo aplicar estos conceptos mediante la caracterización de un problema de negocio real que requiere Big Data. Para ello, se ha seleccionado a Olist, una empresa brasileña de comercio electrónico, y su conjunto de datos público disponible en Kaggle. A través del análisis de las 5Vs, se describirá un problema de negocio específico, la alta tasa de retraso en las entregas, y se propondrá una arquitectura tecnológica para su solución.

Descripción de la Empresa y el Dataset

Olist Store

Olist es el mayor departamento digital en marketplaces brasileños, con sede en São Paulo, Brasil. La empresa actúa como un intermediario que conecta a pequeños comercios de todo Brasil con canales de venta en línea mediante un solo contrato. Los comerciantes pueden vender sus productos a través de Olist Store, y la empresa se encarga de la logística de entrega mediante socios transportistas.

Dataset: Brazilian E-Commerce Public Dataset by Olist

El dataset utilizado en este trabajo es el Brazilian E-Commerce Public Dataset by Olist, publicado en Kaggle bajo el siguiente enlace: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>

Este conjunto de datos contiene información de más de 100,000 pedidos realizados entre 2016 y 2018 en múltiples marketplaces de Brasil. Los datos han sido anonimizados y las referencias a empresas y socios han sido reemplazadas por nombres de casas de Game of Thrones.

El dataset se compone de 8 archivos CSV que conforman un esquema relacional:

Tabla 1

Composición del dataset de Olist

Archivo	Filas	Descripción
olist_customers_dataset.csv	96,000	Datos de clientes (ID, código postal, ciudad, estado)
olist_orders_dataset.csv	100,000	Órdenes (estado, fechas de compra, aprobación y entrega)
olist_order_items_dataset.csv	112,000	Ítems por orden (producto, vendedor, precio, flete)
olist_order_payments_dataset.csv	104,000	Pagos (tipo, cuotas, valor)
olist_order_reviews_dataset.csv	100,000	Reseñas (score, título, comentario, fechas)
olist_products_dataset.csv	33,000	Productos (categoría, dimensiones, peso)

Archivo	Filas	Descripción
olist_sellers_dataset.csv	3,000	Vendedores (ID, código postal, ciudad, estado)
product_category_name_translation.csv	74	Traducción portugués-inglés de categorías

Problema de Negocio

El problema de negocio identificado es el siguiente: **«Alta tasa de retraso en las entregas que impacta negativamente en la satisfacción del cliente, generando reseñas desfavorables , con puntuaciones iguales o inferiores a 2 en la escala de 1 a 5, y provocando una pérdida estimada de 2.5 millones de reales brasileños (BRL) anuales debido a devoluciones, reembolsos y daño a la reputación de la marca.»**

El dataset revela que aproximadamente el 10% de las órdenes presentan retrasos respecto a la fecha estimada de entrega. Este problema involucra múltiples dimensiones: la ubicación geográfica de clientes y vendedores, la categoría del producto, el desempeño del transportista, el valor del flete y la temporalidad de la compra.

La complejidad del problema radica en la necesidad de correlacionar estas variables heterogéneas en tiempo real para construir un modelo predictivo que permita anticipar retrasos y tomar acciones correctivas antes de que afecten al cliente.

Análisis de las 5Vss

A continuación, se caracteriza el problema descrito bajo el modelo de las 5Vs del Big Data:

Volumen

El dataset en su estado original ocupa aproximadamente 3 GB y contiene más de 100,000 registros de órdenes. Sin embargo, para un despliegue a escala de producción, se proyectan los siguientes volúmenes:

Tabla 2

Proyección de volumen de datos a escala de producción

Fuente de datos	Volumen diario estimado	Volumen anual proyectado
Órdenes y transacciones	2.5 GB	0.9 TB
Clickstream (e-commerce)	5 GB	1.8 TB
Tracking de entregas (geolocalización)	1.5 GB	0.5 TB
Reseñas y comentarios de clientes	0.5 GB	0.2 TB
Datos de sensores IoT (logística)	3 GB	1.1 TB
Total	12.5 GB/día	4.5 TB/año

El volumen total estimado asciende a aproximadamente 12.5 GB por día, lo que equivale a unos 4.5 TB al año. Esta magnitud supera la capacidad de procesamiento de bases de datos relacionales tradicionales y justifica el uso de tecnologías Big Data.

Velocidad

La velocidad requerida para el procesamiento se clasifica en tres niveles:

- Streaming en tiempo real para la captura y procesamiento de datos de tracking de entregas, alertas de retraso inminente y detección de anomalías en la cadena logística, con una latencia requerida inferior a 5 segundos.

- Micro-batches cada 5 minutos para la actualización del estado de las órdenes, sincronización de inventarios y agregación de métricas operativas para dashboards en tiempo casi real.
- Batch diario para el entrenamiento y reentrenamiento de modelos predictivos como Random Forest y XGBoost, la generación de reportes semanales de desempeño de vendedores y la actualización de paneles de KPIs estratégicos.

Variedad

Los datos a integrar presentan una alta heterogeneidad de formatos:

Tabla 3

Variedad de formatos de datos en el ecosistema Olist

Tipo	Fuentes	Formato
Estructurados	Tablas de órdenes, clientes, pagos, productos, vendedores	CSV, SQL
Semiestructurados	Logs de servidor web, JSON de API de tracking	JSON, XML, log
No estructurados	Reseñas de texto libre, títulos de reseñas, imágenes de productos	Texto plano, JPG/PNG

Mención especial merecen los datos no estructurados provenientes de las reseñas de clientes, que contienen texto libre en portugués con opiniones, quejas y sugerencias que requieren técnicas de procesamiento de lenguaje natural (NLP) para su análisis.

Veracidad

El análisis exploratorio del dataset revela diversos desafíos relacionados con la calidad de los datos:

Tabla 4

Retos de veracidad y estrategias de mitigación

Problema de calidad	Magnitud	Estrategia de mitigación
Fechas de entrega faltantes en delivered_customer_date	2,965 registros (3%)	Imputación condicional basada en la mediana de días de entrega por estado

Problema de calidad	Magnitud	Estrategia de mitigación
Reseñas sin comentario escrito	58,259 registros (58%)	Análisis basado únicamente en el score numérico; NLP solo sobre comentarios existentes
Categorías de producto vacías	610 productos (1.8%)	Asignación por similitud de nombre del producto o exclusión del análisis
Sesgo en las reseñas (positividad)	Media 4.0/5.0	Balanceo de clases para modelos predictivos; análisis de sentimiento ponderado
Inconsistencias en nombres de ciudades	Múltiples variantes (ej. «sao paulo», «são paulo», «sp»)	Pipeline de estandarización geoespacial con diccionario de normalización
Duplicados potenciales de clientes	Clientes con mismo zip code y ciudad pero distinto ID	Algoritmo de fuzzy matching para deduplicación

La gestión adecuada de estos problemas de calidad es fundamental para garantizar la confiabilidad de los análisis y modelos predictivos derivados.

Valor

El valor estratégico y financiero del proyecto se cuantifica en los siguientes términos:

Tabla 5

Valor estratégico y financiero del proyecto Big Data en Olist

Beneficio	Impacto económico anual estimado
Reducción de devoluciones y reembolsos por retrasos	1.2 MM BRL
Incremento en retención de clientes por mejor experiencia	0.8 MM BRL
Optimización de rutas de entrega mediante analytics predictivo	0.3 MM BRL
Reducción de costos operativos de atención al cliente	0.2 MM BRL
ROI total	2.5 MM BRL/año

Además del impacto financiero directo, el proyecto genera valor estratégico al permitir:

- Ventaja competitiva ya que Olist puede ofrecer a sus sellers un panel de predicción de retrasos, diferenciándose de otros marketplaces.
- Toma de decisiones basada en datos al identificar patrones de retraso por región, temporada o transportista y negociar mejores acuerdos logísticos.
- Personalización del servicio mediante notificaciones proactivas a clientes frecuentes sobre el estado de sus entregas, mejorando la experiencia de compra.

Arquitectura Big Data Propuesta

La arquitectura propuesta para abordar el problema sigue un flujo de procesamiento basado en el modelo Lambda, combinando procesamiento por lotes (batch) y en tiempo real (streaming):

Tabla 6

Arquitectura Big Data propuesta (modelo Lambda)

Capa	Componentes y función
Ingesta	Apache Kafka: Captura de flujos de datos en tiempo real (órdenes, tracking, reseñas) desde las fuentes
Procesamiento batch	Apache Hadoop HDFS: Almacenamiento distribuido del histórico de datos (petabytes). Apache Spark (batch): Procesamiento de datos históricos para entrenamiento de modelos ML
Procesamiento streaming	Apache Spark Streaming: Procesamiento de flujos en tiempo real para detección temprana de retrasos
Almacenamiento analítico	Data Lake (HDFS/S3): Almacenamiento unificado de datos crudos y procesados
Machine Learning	Modelo predictivo Random Forest / XGBoost para predicción de retrasos en entregas basado en variables históricas (distancia, categoría, transportista, precio de flete, temporada)
Visualización	Power BI / Tableau: Dashboards interactivos con KPIs como porcentaje de entregas a tiempo, score promedio por vendedor y tasa de retraso por categoría de producto

Conclusiones

El análisis del caso de Olist permite extraer las siguientes conclusiones:

1. El Big Data no se define únicamente por la cantidad de datos almacenados, sino por la capacidad de transformar un ecosistema masivo y caótico , caracterizado por las dimensiones de volumen, velocidad y variedad , en decisiones empresariales confiables (veracidad) y rentables (valor).
2. El problema de los retrasos en las entregas en Olist constituye un caso paradigmático de aplicación de Big Data, pues involucra las 5Vs de manera integral: grandes volúmenes de datos transaccionales y de tracking, procesamiento en tiempo real para alertas tempranas, integración de formatos diversos (estructurados, semiestructurados y no estructurados), desafíos significativos de calidad de datos y un impacto financiero cuantificable.
3. La arquitectura Lambda propuesta, combinando Apache Kafka para la ingesta, Apache Spark para el procesamiento batch y streaming, y un data lake como repositorio unificado, ofrece una solución escalable y robusta para abordar la complejidad del problema.
4. El dataset público de Olist, disponible en Kaggle, demuestra que incluso con datos abiertos es posible realizar un análisis exhaustivo de las 5Vs y construir propuestas de valor basadas en Big Data, nivelando el campo de juego para pequeñas y medianas empresas que buscan competir con grandes corporaciones.